


Функциональный результат на 60 задачах SWE-bench Verified



Вертикальные интервалы: 95% Wilson CI для каждой доли; сравнение методов является парным.